

中期进展报告

妈祖风云 MAZU-FENGYUN · 沙特阿拉伯

多灾种人工智能早期预警系统

2026 MAZU 全球智能创新应用挑战赛

北京化工大学 · 指导老师：李瑞瑞

3

覆盖灾种

7

智能体工具

237

单元测试

121/121

全系统审计通过

摘要

MAZU-Saudi 是一个已实际构建、已充分测试、并已公开部署的多灾种早期预警系统，覆盖沙特阿拉伯 8 个城市的 **山洪、极端高温与沙尘暴** 三种灾害。系统由五层构成——数据管线、文献支撑的因果知识图谱、基于规则的探测引擎、经严格验证的 $t \rightarrow t+1$ 真实预测模型，以及一个具备 7 个独立测试工具的 DeepSeek 函数调用智能体——并已在 turgutino.github.io/mazu-saudi-warning 上线。

本项目每一项决策背后的指导原则是“**如实披露，不夸大**”：下文每一项扩展功能都至少附带一项经独立验证的真实发现——包括那些揭示系统真实局限性的发现——如实报告，而非隐瞒。本报告中的所有数字均直接取自项目自身的测试套件、审计日志与已保存的模型元数据，而非估算值。

60 /
183

知识图谱节点/边

0.971

高温模型 ROC-
AUC

0.873

山洪模型 ROC-
AUC

0.887

沙尘暴模型 ROC-
AUC

6

同行评审文献引
用

五个层次，每一个的构建都是因为前一个留下了一个真实的未解问题。这条链条——而不仅仅是最终的数字——才是本报告接下来要呈现的内容。

一、项目背景与任务定位

沙特阿拉伯长期面临高频、高影响的极端天气风险——西南 Asir 山脉与红海沿岸的山洪，炎热内陆地区的极端高温，以及由夏季 Shamal 风系驱动的沙尘暴——但目前缺乏一个统一的、以人工智能驱动的多灾种早期预警系统。本项目的任务即是构建这样一个系统，分辨率以原始数据实际能支撑的为准（ 0.1° ，约10公里网格——城市/区域级，而非真正街区级预警所需的约100-500米级；见第十一节）：从中国气象局（CMA）提供的原始网格化指标数据，一路贯通到自然语言预警智能体，遵循 MAZU 自身的全国早期预警框架（多灾种·预警·零差距·普惠）。

二、系统架构 — 五层结构

层级	组件	状态	说明
0	数据管线	✓	将 365 个逐日 NetCDF 文件 (0.1° / 10 km 网格) 整合为一个分析就绪的数据集，含 22 个核心可信指标。
1	知识图谱	✓	60 个节点 / 183 条边——指标、灾种、机制、区域、带真实观测值的 2025 年真实事件，以及 6 条同行评审文献引用。
1	探测引擎	✓	加权多条件规则 + 空间连通分量聚类，已针对 2025 年已知事件完成验证。
2	预测模型 ($t \rightarrow t+1$)	✓	每种灾害独立的梯度提升时空分类器，训练于 2025 年 1–6 月，测试于完全未见过的 7–12 月。
3	因果溯源	✓	灾害机制均溯源至 6 篇真实引用文献中逐字核实过的原文段落（另有 7 篇候选中的 1 篇在人工质量核查后被排除，见第七节）。
4	智能体	✓	DeepSeek 函数调用智能体，具备 7 个独立测试的工具，生成有据可查的自然语言回答。

三、数据基础

数据来源：老师提供的 `saudi_indicators_YYYYMMDD.nc` 文件，共 365 个逐日文件（完整 2025 全年），约 5 GB，0.1° 分辨率，覆盖沙特矩形范围（北纬 16.0–32.0° / 东经 34.0–55.9°，160×220 网格，共 35,200 个格点）。从原始文件每日 26–91 个可用变量中，筛选并质检出 22 个核心指标（公式复算、空间范围检查、缺测值清理），并明确区分**核心可信**指标（直接用于建模）与**辅助解释**指标（源自稀疏站点气候态的距平字段，仅用于叙述性背景，从不单独作为判定阈值）。

四、知识图谱

60 个节点 / 183 条边，涵盖 7 种节点类型（指标、灾种、区域、机制、事件、文献、数据源）与 11 种边类型。每个事件节点的观测值均可追溯至该日原始文件网格最大值——并非虚构。知识图谱中的因果机制边溯源自 6 篇引用文献中逐字核实的真实原文（如 de Vries et al. 2013, *JGR-Atmospheres*; Yu et al. 2016, *JGR-Atmospheres*）——另有 1 篇候选文献在人工质量核查后被排除，详见第七节。

自我发现的缺口，已披露并部分弥补：内部审计发现，智能体工具此前仅实际调用了知识图谱 11 种边类型中的 3 种（约占全部边的 20%），尽管该图谱在公开网站上被标注为“可交互”。为

此专门构建了第 5 个智能体工具 `region_risk_tool`，将实际使用率提升至约 40% 的边——仍如实披露为“尚未完全”，而非夸大为已解决。

五、探测引擎（第一层）

每种灾害均配备加权多条件规则引擎（基于数据本身的百分位阈值，而非任意设定的截断值），并通过空间连通分量聚类将风险归并为离散事件（区域、严重程度、峰值风险、触发条件）。已针对 2025 年已知事件及空间气候态负对照完成验证。该引擎还承担第二项职能：作为机器学习预测模型的**独立交叉校验信号**（见第九节“反思式自检”）。

像这样的规则引擎可以告诉你灾害正在发生。但它本身无法预测灾害——这一缺口正是第二层存在的意义。

六、预测模型（第二层）— 真正的 $t \rightarrow t+1$ 预测

明确说明预测时效：本节所有数字都**仅为提前1天**的预测（ $t \rightarrow t+1$ ——用今天的指标预测明天的风险）。系统目前不产出2天、3天或一周的预测；延长预测时效需要不同的训练/评估设置，属于未来工作（见第十四节），并非已经交付的功能。

每种灾害均有独立的 `HistGradientBoostingClassifier` 模型，训练于 2025 年 1–6 月，在完全未见过的 2025 年 7–12 月后半年上进行评估——这是真正的**预测**（用今天的指标预测明天的风险），而非把“当日探测”包装成“预测”。

灾种	ROC-AUC	PR-AUC	POD	FAR	CSI	HSS	业务阈值
极端高温	0.971	0.795	0.849	0.388	0.552	0.693	0.55
山洪	0.873	0.089	0.100	0.803	0.071	0.130	0.50
沙尘暴	0.887	0.164	0.535	0.865	0.121	0.190	0.55

POD/FAR/CSI/HSS 为 WMO 标准列联表指标，在各灾种自身的业务阈值下计算（与 CAP 预警严重等级使用的阈值相同），基于已保存的生产模型直接计算，本表未重新训练模型。

指标	计算公式	通俗含义
POD（探测概率）	$TP / (TP + FN)$	在所有真实发生的极端日中，系统标记出了多少比例？（“命中率”/召回率。）1.0 = 从不漏报真实事件。

FAR (虚警率)	$FP / (TP + FP)$	在所有系统标记的日子中，有多少比例是虚警？0.0 = 每次预警都是真实的。（与"相对于所有平静日的虚警率"是不同概念。）
CSI (临界成功指数)	$TP / (TP + FN + FP)$	在所有"真实发生或被标记预警（或两者皆是）"的日子中，有多少比例被正确标记？同时惩罚漏报和虚警，也称为"威胁评分"。
HSS (Heidke 技能评分)	$(TP + TN - E) / (N - E)$ ，其中E为按随机猜测预期正确的次数	相对于随机猜测基线的技巧水平。0 = 与随机猜测无异；1.0 = 完美。同时奖励对两类结果（事件日与平静日）的正确判断，而非仅关注稀有的正类。

TP/FP/FN/TN = 真阳性 / 假阳性 / 假阴性 / 真阴性，均来自业务阈值下的同一混淆矩阵。以上全部4个公式均由 `model/08_meteorological_metrics.py` 中的 `contingency_metrics()` 函数直接计算得出，而非近似估算或查表所得。

真实的、如实披露的发现：山洪模型具有很强的、与阈值无关的 ROC-AUC (0.873)，但在其固定的业务阈值下 POD 却很低 (0.10)。这并非矛盾——这正是极端稀有事件（测试集中样本占比约 0.5%）的预期表现，也正是 POD/FAR/CSI/HSS 存在的意义：揭示单靠 ROC-AUC 无法看到的信息。我们如实报告了这一结果，而非只展示更"好看"的 ROC-AUC 数字。

同样经过测试并如实报告：曾测试一个时空图神经网络（GNN）变体，与梯度提升基线模型对比。该模型在某一已知山洪事件上提升了空间召回率，但整体校准性能下降——作为已记录的研究方向保留，**未部署**到生产环境。另外还测试了一种更廉价的空间上下文特征（关键指标的邻域均值）：该特征对高温模型有效（现已成为高温生产模型的一部分），但使山洪模型变差，因此正确地**未用于**该灾种。

仅有好看的排序指标还不足以让人信任——下一个问题是，模型给出的概率数值是否真的意味着它所声称的含义。这个问题驱动了三项独立的实验（见9.9–9.12节），而它们的结果并非都如预期。

七、因果溯源（第三层）

通过大语言模型从 7 篇真实引用文献中提取了 21 条候选因果三元组，并强制要求每条提取都附带逐字引用原文字段；每条引用都会自动与原文重新核对。其中一条三元组虽通过了自动核验，但人工复核后发现存在循环论证问题，因此被如实披露并剔除，而非为凑数保留。

为何只有7篇文献，而不是更多：每一篇候选论文都要经过一套人工流程——找到真实的、可引用的来源，直接阅读原文（而非搜索摘要），撰写忠实的转述，通过逐字引用提取核验闸门，并对每一条通过的三元组进行人工循环论证复核后才予以采信。这个过程刻意保持缓慢，因为系统中的每一个事实都必须能够单独经受住检验；选择较小但完全可核实的语料

库，而非较大但未经核实的语料库，是一个设计决策，而非被动接受的资源 限制。第9.13节将同样的"质量优于数量"原则延伸到了新增的5篇论文上，采用完全相同的阅读并核实标准。

八、智能体层（第四层） — 7 个经独立测试的工具

序号	工具	作用
1	forecast_tool	t→t+1 风险概率，附带海拔 / 地形提示、人口背景信息、反思式独立交叉校验，以及5模型集成不确定性信号（见9.12节）。
2	causal_kg_tool	某灾种的驱动机制及其文献引用。
3	conditions_tool	某城市 / 日期的实际观测原始指标值。
4	similar_events_tool	将某城市 / 日期的指标与知识图谱中已知的 2025 年真实极端事件进行 Z 分数相似度比较。
5	region_risk_tool	以城市为切入点的"该地区应关注什么风险"查询，基于知识图谱 at_risk_of / exposed_to 边。
6	cap_alert_tool	将预测结果转换为符合 CAP 1.2（通用预警协议）标准的 XML 预警消息。
7	literature_evidence_tool	为知识图谱未覆盖的城市 / 灾种组合提供候选（未验证）文献依据（见9.13节）。

系统提示词严格禁止陈述任何未经实际工具调用得出的概率、指标值、机制名称或文献引用——已通过 169 个单元测试 与 4 个端到端真实场景验证。

通过真实 A/B 消融实验证明，而非仅凭口头声称：将同样 4 个"为什么"类问题分别在 保留 causal_kg_tool 与移除该工具的情况下运行。保留时：4/4 的回答引用了真实驱动机制与文献；移除后：0/4 做到——且关键的是，0/4 出现了编造机制的幻觉；智能体如实回答"没有可靠依据"。

一个正确的模型和一个正确的知识图谱，若无法被整合起来回答一个具体问题，也不过是文件里的一堆数字。这正是本节接下来的内容——七个工具，每一个都是因为某个具体问题若没有它就无法回答而被构建出来的。

九、已构建的扩展功能 — 每项均附带真实、经验证的发现

9.1 地形 / 海拔背景信息

`forecast_tool` 现会对山区城市（Abha、Taif，海拔 ≥ 1500 米）的预测结果标注"置信度较低"。构建该功能时发现了一个真实的、此前未记录的模型局限：在陡峭的 Asir 山脉地区，模型使用的粗网格特征点 可能比城市真实海拔低约 750 米。

9.2 基于影响的人口背景信息

每次预测现均返回该城市 2022 年人口普查数据（GASTAT），并明确标注为"仅供参考背景"——绝非受灾人数的估计值，因为本系统并未进行暴露度 / 脆弱性建模。遵循 WMO 基于影响的预警指南。

9.3 反思式自检

每次机器学习预测现均与第一层的独立、基于规则的探测引擎在同一天原始指标上进行交叉验证（一种 Reflexion 式的一致性检查）。此举发现了两项真实、已披露的结果：8 月 23 日（Jizan），风暴前一天的物理前兆条件已经显著升高，而模型当时仅给出 12.5% 的概率——一个模型低估了的真实先兆信号；7 月 25 日（Mecca），模型正确标记出一次异常高温事件，而探测引擎基于固定绝对阈值的规则完全未能捕捉到——这是机器学习模型确实提供了超越简单阈值判断的附加价值的真实证据。

9.4 历史相似事件检索（第4个工具）

`similar_events_tool` 将某城市 / 日期的指标与知识图谱中已知的真实事件进行 Z 分数相似度比较。测试中发现了一个真实的、经过调查的现象：事件节点的坐标是其自身网格单元的极值点（风暴/高温中心），往往与同名城市中心相距数十公里，因此同城市同日期的查询可能与"自己的"事件呈现较低相似度——现已在结果中 明确标注该距离，而非造成隐性混淆。

9.5 沙尘暴 — 第三种灾害，全深度构建

并非仅停留在探测层面：从全部 365 个原始文件中处理出 2 个新的原始指标，构建了基于数据的探测规则，训练并完成了样本外验证的预测模型，且知识图谱的关联溯源**无需提取任何新文献**——知识图谱中已有的 Shamal 引用（Yu et al. 2016）本就指出夏季 Shamal 是阿拉伯半岛沙尘暴活动的主要驱动力，因此沙尘暴被正确地 关联到这一已有的文献支撑，而非另行编造。

测试中发现的真实方法论问题：沙尘暴首次已知事件验证时，意外使用了落在训练期内的日期（存在数据泄漏风险）；在报告前被及时发现并纠正为真正落在测试期内、模型从未见过的
事件。

9.6 region_risk_tool — 第5个工具，弥补自我发现的知识图谱缺口

详见第四节。该工具还发现了另外两项结果：并非知识图谱中每个灾种都配有已训练的预测模型（如"coastal"沿海风险——系统对此妥善处理，不会返回捏造的预测结果）；以及一个真实存在、早于本次工作的知识图谱数据质量缺口（Jeddah 被标记为面临高温风险，但其 `exposed_to` 机制与高温灾害实际驱动机制并无重合——经追溯，源于最初手工编码的领域知识，该问题被如实披露，而非悄悄修补掩盖）。

9.7 CAP 1.2 预警生成 — 第6个工具

`cap_alert_tool` 将预测结果转换为符合 OASIS 国际标准 CAP 1.2 的真实 XML 预警消息——这正是 MAZU 自身国家级预警框架所采用的传输格式——可直接对接广播 / 警报器 / 短信等基础设施。严重等级源自探测引擎自身的阈值；确定性等级源自反思式自检中模型与规则引擎的一致程度；`status` 字段被硬编码为 `Exercise`（演习），绝不会是 `Actual`（实际），因为本系统运行于历史数据集之上，而非实时数据源。

真实发现：某一天模型与独立探测引擎均一致认为风险已升高（反思式检查结果为 `consistent_elevated`），但该概率仍可能低于 CAP 预警自身（刻意设定更高）的发布阈值——反思式检查与预警发布阈值本就是在回答两个不同的问题，这是设计使然，而非缺陷。


9.8 WMO 标准验证指标（POD/FAR/CSI/HSS）

作为WMO自身针对灾害预报的业务化验证标准而采纳，而非仅依赖ROC-AUC/PR-AUC。结果与山洪模型的相关发现详见第六节。

9.9 可靠性曲线 — 概率本身是否可信？

ROC-AUC 与 POD/FAR/CSI/HSS 回答的是与"当模型说 70% 时，是否真的有 70% 的概率发生"完全不同的问题。将测试集中每一次预测按概率分桶，并将预测值与实际观测频率对比作图，回答的正是这个问题。

真实的、如实披露的发现：三种灾害均表现出**系统性的过度自信**。山洪的"95.7%"分桶实际只有 54.3% 的时候真的发生；沙尘暴的"94.9%"分桶只有 20.4%。山洪的整体 ECE (0.006) 单独看是三者中最好的，但这本身具有误导性——其测试样本中约 97% 落在同一个接近零的分桶中，掩盖了高概率端同样存在的过度自信问题。这与第9.7节直接相关：CAP"Extreme" 严重等级正是基于这些同样存在一定"虚高"的原始概率触发的。



三种灾害的每一个点均落在"完美校准"对角线下方。

一个已被证实的问题，以及一个显而易见的下一步：用标准的校准技术来修复它。测试了两种方法。两种都没有像教科书说的那样奏效。

9.10 能否修复？Isotonic 重新校准 — 已测试，未部署

采用无数据泄漏的三段式按时间划分方案（独立分类器仅用1–5月训练，isotonic 校准器仅用6月数据拟合，最终在与其他报告完全相同、从未被触碰过的7–12月测试集上评估），检验标准的事后概率校准方法能否解决该问题。

灾种	Brier (修复前→后)	ECE (修复前→后)	ROC-AUC (修复前→后)
极端高温	0.0273 → 0.0265	0.014 → 0.023 (变差)	0.9548 → 0.9551
山洪	0.011 → 0.0049	0.022 → 0.003	0.9039 → 0.8974
沙尘暴	0.0643 → 0.0193	0.099 → 0.014	0.8018 → 0.8010

三种灾害的 Brier 分数均有所改善。但第二项实验——在完全隔离的沙盒环境（未触碰本仓库、已保存的模型或 GitHub）中实际构建并测试了完整的生产环境迁移方案——发现了一个更严重的问题：若沿用旧的预警阈值，**沙尘暴校准后的概率在整个测试集中从未超过 0.50**，导致其预警在结构上永远无法触发。随后针对每种灾害 重新推导了阈值（在保留的校准月份上以 CSI 最大化为目标，绝不使用测试集数据——符合标准气象业务验证做法）——但即便采用各灾种自身的最优阈值：

灾种	旧阈值	新阈值	POD (修复前→后)	CSI (修复前→后)
极端高温	0.55	0.32	0.849 → 0.749	0.552 → 0.472
山洪	0.50	0.18	0.100 → 0.045	0.071 → 0.043

沙尘暴	0.55	0.18	0.535 → 0.341	0.121 → 0.119
-----	------	------	---------------	---------------


每一种灾害的真实预警发布质量都变差了，而非变好。校准修复了概率的"诚实性"，但没有保持——反而在可测量的程度上损害了——决策的"质量"。**因此未予部署：**这一结论是通过实际构建并完整测试 整个迁移方案得出的，而非仅凭风险推测。生产环境的 `saved_models/*.joblib` 及全部 143 个智能体测试 均未受影响。

一种标准修复方法，经过如实测试后反而让情况变糟。在断定这个问题无法修复之前，第二种不同的技术同样值得进行一次真实测试。

9.11 更温和的替代方案？5模型集成 — 同样经过测试，同样未部署

将 5 个独立训练的分类器（超参数与训练窗口与生产模型相同，仅随机种子不同）的预测取平均，与实际保存的 生产模型在相同的现有阈值下进行对比（无需重新推导阈值——一次直接、公平的比较）：

灾种	ROC-AUC (单模型→集成)	POD (单模型→集成)	ECE (单模型→集成)	Brier (单模型→集成)
极端高温	0.9706 → 0.9704	0.849 → 0.841	0.039 → 0.036	0.030 → 0.029
山洪	0.8732 → 0.8732	0.100 → 0.080	0.006 → 0.004	0.006 → 0.006
沙尘暴	0.887 → 0.893	0.535 → 0.527	0.085 → 0.087 (变差)	0.060 → 0.059



三种灾害的 Brier 分数均有小幅改善，但 POD 在三种灾害中均变差，沙尘暴的 ECE 甚至出现了倒退——这是一个真实但微小、且不一致的改善，并非期望中的"干净"解决方案。从图中可见，集成模型的可靠性曲线（下排）与单模型（上排）几乎难以区分。根本原因：5 个成员共享相同的架构 / 特征 / 数据，仅随机种子不同，其多样性不足以真正修正过度自信的模式。**结论——用两种不同的标准技术分别测试两次后得出：在本项目中，校准与业务决策质量是两个相互独立的问题，修复其中一个并不能可靠地修复另一个——这本身就是一项真实、有价值的研究发现。**

两次诚实的尝试，两次真实的负面结果——都保留在本报告中，而非悄悄舍弃。这留下了一个此前无人尝试过的选项：不再试图修复这个数字，而是如实地讲清楚它的问题所在。

9.12 集成不确定性 — 最终采用并部署的方案

第9.10节与第9.11节都试图通过**改变概率点估计本身**来修复过度自信问题，但两者都以可测量的方式损害了 预警业务质量。为第9.11节已训练好的5模型集成，这次改用另一种方式重新利用：不再将5个成员的预测取平均得出 新的点估计，而是直接暴露它们之间的**分歧程度**。

`forecast_tool` 现新增第4个返回字段 `uncertainty`（包含 `mean` / `std` / `range` / `n_members`），基于同样5个独立训练的模型对当前具体输入实时计算得出——它仅作为附加背景信息呈现，绝不会替代生产环境的 `probability` 字段。

实际案例 — `forecast_tool("Jizan", "2025-08-23", "flash_flood")`: `probability: 0.1253`, `uncertainty: {mean: 0.1143, std: 0.0486, range: [0.0433, 0.185], n_members: 5}`。这里5个模型的预测分歧约为 ± 0.05 ——如实呈现出一个中等置信度的情形，而非一个虚假精确的单一数字。

为何此方案能成功，而第9.10–9.11节的方案未能成功：因为没有任何决策相关的数值发生变化，所有已验证的测试 / 审计数值以及 CAP 预警阈值均保持不变——过度自信这一发现由此获得了一个诚实的、增量式的回应，而非一次以牺牲探测质量为代价的点估计重写。这也是一个与 `forecast_tool` 已有的另外两个可信度字段 截然不同的独立信号：`reflexive_check` 是将机器学习模型与一个独立的基于物理规则的引擎相比较；`meteorological_metrics` (POD/FAR/CSI/HSS) 描述的是模型固定的历史业务表现记录；而 `uncertainty` 衡量的则是5个原本完全相同的模型在这一具体输入上彼此分歧的程度——即便另外两个信号 均表现良好，该值仍可能很高，反之亦然。

独立验证方式：`agent/02_test_tools.py` 新增了8项检查（字段结构、确定性、range合法性，以及一项 直接加载5个原始集成模型文件的旁路验证）；`FULL_SYSTEM_AUDIT.py` 新增 Section O，从磁盘重新加载全部 15个原始集成模型文件（绕过所有内部缓存），针对独立重建的测试集从零重新计算每个种子模型的 ROC-AUC，并从原始 数据集数组重新构建 Jizan 的特征行，确认 `uncertainty.mean/std/range` 与实时工具输出完全一致。

三项实验，一条主线：先发现一个真实问题（第9.9节），再经历两次诚实的直接修复失败（第9.10–9.11节），最后第三次尝试之所以成功，恰恰是因为它不再试图掩盖问题，而是选择了如实披露。

9.13 literature_evidence_tool — 弥补文献引用覆盖缺口（第7个工具）

正式的因果知识图谱目前只有 6 条经人工核实的文献引用（见第七节），支撑 5 种机制。部分城市 / 灾种组合完全没有正式的支撑——`region_risk_tool` 自身披露的发现是：Jeddah 被标记为面临高温风险，但其 `exposed_to` 机制与高温灾害实际的 `driven_by` 机制毫无重合（见9.6节）。此项扩展源于与项目导师的一次真实对话，讨论 **Relink**（`Relink: Constructing Query-Driven Evidence Graph On-the-Fly for GraphRAG`，GitHub: `DMiC-Lab-HFUT/Relink`）——这是导师分享的一份文档中最初为建筑智能化 RAG 场景提出的 技术。导师正确地指出，Relink 本身是与领域无关的通用技术——建筑智能化场景只是其中一个应用案例，并非该 技术本身的局限。

在决定如何借鉴之前，**直接阅读了 Relink 的实际参考实现代码**（而非仅看论文摘要）：其检索器执行基于 LLM 的主题实体提取、在正式知识图谱与更松散的共现图之间进行 Neo4j 束搜索，并且——关键在于——存在一个 **由 LLM 推测松散共现所代表的具体关系类型**的步骤。这是一个生成式、未经验证的推理步骤，正是本项目在 其他所有地方都严格防范的那类风险（`02_extract_causal.py` 中的逐字引用校验闸门；每份报告中 "绝不陈述没有工具结果支撑的

事实”的规则)。其路径排序器还需要一个单独训练、通过 Redis 提供服务的神经网络模型。考虑到 MAZU 的语料库规模 (12 条文献条目, 而非 Relink 针对的每日数千条日志), 这样的基础设施是不必要的。

未直接照搬 Relink 的完整原因 (不只是“太复杂”——五条独立、如实披露的约束):

1. **基础设施:** Neo4j + Redis 不属于 MAZU 现有技术栈 (纯 Python + 本地文件); 为一个仅 12 条的语料库 专门搭建并运维两套新服务, 投入产出明显不成比例。
2. **路径排序器缺少训练数据:** Relink 的神经网络排序器需要“查询→正确证据”标注数据对才能从零训练, 或者使用 Relink 自己的预训练权重 (该权重是为其自身评测领域训练的, 并非针对中东气象领域) ——MAZU 两者 都不具备。
3. **规模不匹配:** Relink 整套设计的初衷是避免在庞大且持续增长的语料库上反复重建代价高昂的图谱; 而 MAZU 仅 12 条的语料池在每次调用时都能在毫秒级从零重建, Relink 所要解决的问题在这个规模下根本不存在。
4. **可审计性:** 训练过的排序器或 LLM 推测出的关系, 不像 TF-IDF 那样能够从原始文本精确、可重复地 推导出来——这会打破 `FULL_SYSTEM_AUDIT.py` 一贯坚持的要求, 即每一个输出结果都必须能够独立 地从零重新推导, 而不仅仅是重新运行一遍。
5. **时间:** 这是一个期中阶段的交付物; 在完全没有标注数据的情况下搭建数据库并训练或微调一个排序器, 需要耗费数天时间——而这仅仅是为了一个被明确标注为“未验证”的辅助信号功能, 并非系统的核心预测路径。

不使用重型技术栈, 是否本可以做得更深入? 如实回答: 是的, 存在一条中间路线, 但出于工作量/时间考虑并未采用——即基于 12 条文献中共现的机制 / 指标术语, 用进程内图 (例如 Python 的 `networkx`, 无需外部服务器) 构建一次真正的图结构, 并支持跨文献的多跳推理 (这正是 Relink 真正的价值所在: 把论文 A 中的一个事实与论文 B 中的另一个事实组合起来, 而单独任何一篇论文都没有同时 陈述这两点)。目前的工具只返回单篇文献的 top-k 匹配结果——并不会跨文献串联证据。在仅有 12 条数据的规模下, 预期收益较小, 因此这是一个经过权衡后主动降低优先级的决定, 而非尝试后放弃; 这是该功能最具体的“下一步版本”方向 (见第十四节)。

`literature_evidence_tool(city, hazard)` 因此只借鉴 Relink 的思路, 而非其技术栈: 使用简单的 TF-IDF 余弦相似度 (`sklearn`, 项目已有依赖) 在文献池中检索——文献池包含原有 7 条提取语料 (其中 6 条已被正式知识图谱采纳, 1 条经人工质量核查后未采纳, 见第七节), 加上**新增的 5 条**, 均为专门为此工具重新研究、直接抓取并阅读原文后写入 (另有 4 篇有潜力的论文因直接抓取时返回 HTTP 402/403 而被舍弃, 而非依据未经核实的搜索摘要转述)。每一条结果都被永久标记为 `verified: false`, 除非有人工将其送入与原有 7 条引用相同的逐字引用核实流程, 否则不会被采纳。

测试中发现并修复的一个真实缺陷: 初版实现使用带下划线的原始灾种字符串 (如 `flash_flood`) 构造查询, 而语料库文本中是带空格的自然语言 (“flash flood”), 导致完全匹配不上——除高温 / Jeddah 组合外, 几乎所有查询都悄悄退化为同一个通用的、无意义的

前5名结果。该问题是在正式编写测试之前，通过人工检查一份6组合分数打印结果时发现的，而非想当然地认为实现正确；修复后，已针对全部24个城市×灾种组合固化为回归测试。

实际案例——`forecast_tool` 自身的一个缺口：`literature_evidence_tool("Jeddah", "heatwave")` 检索到一篇2023年发表于 *Land* (MDPI) 关于 Jeddah 城市热岛效应的论文（2000–2021年城区扩张约80%，超过80%的城区被划分为极高城市热岛 等级）作为最相关候选——这是一个合理但明确标注为未经验证的潜在驱动因素，正式知识图谱尚未将其与该城市 关联。

独立验证方式：`02_test_tools.py` 新增18项检查（字段结构、每条结果的 `verified: false` 不变量、分数排序、下划线归一化回归测试、逐字节比对摘录完整性，以及全部 24个组合的覆盖测试）；`FULL_SYSTEM_AUDIT.py` 新增 Section P（9项检查），使用全新的向量化器从原始 `corpus.py` 文本重新构建 TF-IDF 矩阵，并针对全部24个城市×灾种组合（而非抽样）确认 与实时工具输出完全一致。

十、测试与验证方法

本项目中的每一项扩展均遵循同一套流程：构建 → 独立单元测试 → 将任何异常都视为潜在真实发现进行调查（绝不 轻率归为“测试问题”）→ 集成 → 智能体真实调用健全性检查 → 扩展全系统审计 → 更新公开文档 → 三重安全扫描 → 提交代码 → 推送 → 验证已部署的线上站点。

237

单元测试，0 个失败

121 / 121

全系统审计通过

4

端到端真实智能体场景

`FULL_SYSTEM_AUDIT.py` 不信任任何中间产物文件：每一项检查都直接重新读取原始 5 GB 数据源（365 个逐日 NetCDF 文件），独立重新推导每一个数字，再与数据管线 / 知识图谱 / 智能体的实际输出进行比对——任何不一致都判定为失败，而非仅作警告。该脚本还会独立地从原始数据重新构建测试集，加载已保存（从未重新训练）的生产模型，基于全新的混淆矩阵重新推导 POD/FAR/CSI，并重新解析实际生成的 XML（而非 Python 字典）以确认 CAP 合规字段。

这正是本项目“严谨核验”在实践中的含义——不是一句口号，而是一套具体的、可重复的流程，应用于第九节中的每一项扩展，包括那些最终“未予部署”的扩展。

十一、如实披露的局限性（未加掩饰）

- **空间分辨率是城市/区域级（0.1°，约10公里网格），而非街区级**——本报告早期版本曾用“街区级分辨率”描述系统的目标，这夸大了10公里网格实际能达到的效果（真正的街区级

预警大约需要100-500米级)。一次有针对性的 核验直接验证了这一差距的实际影响:将模型与一次真实的、官方通报的事件(2025年12月9-10日吉达6小时179毫米 特大洪水)进行核对,发现无论是模型预测还是原始网格数据本身,都没有反映出这次事件——最可能的原因是,这种 短时、高度局地化的强对流降水事件,被10公里网格的空间平均效应"抹平"了。这是一个真实的数据分辨率局限, 如实披露,而非模型逻辑上的错误。

- **山洪模型在其业务阈值下 POD 确实偏低** (0.10) ——这是极端稀有事件带来的真实效应,而非建模错误, 但确实是该灾种特有的实际局限(见第六节)。
- **三种灾害模型在高概率区间均存在系统性过度自信** (见第9.9节) ——测试了两种标准的点估计修复方法(isotonic 重新校准、5模型集成;见第9.10-9.11节), 均未能在不损害预警业务质量(POD/CSI/HSS)的前提下实现干净的改善, 因此均未予部署。取而代之, 部署了一个集成不确定性字段, 作为不改变任何已验证数值的诚实、增量式信号(见第9.12节)。
- **知识图谱边的实际使用率约为 40%, 尚未达到 100%**—— `correlates_with`、`sourced_from`、`manifests_as`、`occurs_at`、`observed_value` 等边类型仍未被任何智能体工具实际使用(见第四节)。
- **已发现并披露一处早于本工作存在的知识图谱数据质量缺口** (Jeddah / 高温机制不匹配问题)(见第9.6节)。
- **正式文献引用池仍然较小** (6条经人工核实的引用, 另有7篇候选中的1篇经质量核查后排除) ——这是权衡了每条引用背后人工阅读并核实的 成本后做出的、质量优于数量的主动选择(见第七节), 而非疏漏。`literature_evidence_tool` (见第9.13节) 可为缺口提供候选文献, 但每条结果在人工通过相同的逐字引用核实流程之前, 都会永久保持 `verified: false`, 该工具本身并不会扩充正式知识图谱。
- **尚不支持阿拉伯语** ——系统目前仅能以英文作答。
- **尚未对接 CAP 表单 / 官方发布渠道** ——CAP XML 已可正确生成, 但尚未接入实际的广播 / 警报器 / 短信网关 (超出本演示系统范围)。
- **静态展示页面, 非实时对话** ——GitHub Pages 无法运行 Python 后端, 也无法安全地在客户端保存 API 密钥, 因此公开网站展示的是真实、已验证的对话记录, 而非实时智能体。

这样一份清单很容易被写成一种自我辩护。但当你注意到清单上的每一项, 要么推动了第九节中的下一项扩展, 要么推动了紧随其后的核验工作时, 它读起来就完全不同了。


十二、针对2025年真实事件的时空验证

老师们要求提供风险的空间视图(地图, 而不仅仅是按城市展示"实际 vs. 预测"的时间序列), 需要同时覆盖全部8个城市、覆盖多天, 以便气象专业人士能够自行核验系统的空间表现, 而

不是仅凭文字描述。本节为已经以逐城市时间序列形式核验过的 同3个真实、官方通报的2025年事件补充了这一空间视图：一次全国性沙尘暴（5月16-19日，达曼）、一次全国性高温热浪（6月10-14日，达曼）、以及一次历史性特大洪水（12月8-11日，吉达）。


每张地图叠加两个独立计算的图层，均为本报告直接从原始数据集重新推导（非缓存或估算值）：

- **真实 (REAL)** ——基于规则引擎的真实风险得分 (Layer 1的 `DetectionEngine.risk_field`，与第一节探测规则采用相同的加权阈值逻辑)，在每个网格点独立于机器学习模型计算得出。
- **预测 (PREDICTED)** ——训练模型给出的预测概率（与 `forecast_tool` 相同的 $t-1 \rightarrow t$ 逻辑），但在每个网格点上计算，而不仅仅是8个城市点。在用于本地图之前，已通过覆盖3种灾害、5个城市、多个日期的10项抽样检查，确认其与 `forecast_tool` 的输出精确一致（精确到小数点后4位）。




沙尘暴 (达曼)："真实"一行显示5月17-18日沿海湾海岸、达曼附近有一条橙红色条带，与此前已报告的城市级探测结果一致。"预测"一行显示的高风险区域更宽、更"嘈杂"——这是一个如实的差异，而非缺陷：模型的概率场是连续的，空间上不如规则引擎 基于阈值的场那样锐利。

Dammam heatwave, 11-14 June 2025 -- model crosses threshold, rule-engine ground-truth stays below 45C locally



高温热浪（达曼）： 这张地图揭示了单城市时间序列未能显示的一个真实局限：在整个时间窗口内，"真实"一行在达曼 始终保持绿色/黄色（规则引擎要求当地 $t_{max} \geq 45^{\circ}\text{C}$ ，而达曼格点的峰值仅为 44.2°C ），而"预测"一行则持续显示高风险。模型的判断方向正确，也与所报告的区域性高温事件相符（该事件 49.3°C 的记录测量点为Al-Ahsa，并非本系统建模的8个城市之一），但规则引擎的真实性核验并不能像沙尘暴案例那样，在达曼的确切坐标上独立确认这一事件。这一"两个事件核验严格程度不一致"的问题是在构建本地图过程中被发现的，这里如实披露，而非掩盖。

Jeddah historic flood, 8-11 Dec 2025 -- neither model nor raw 10km grid captures the event




特大洪水（吉达）： 在全部4天中，吉达当地的两行均保持绿色，与第十一节披露的分辨率局限一致。有一点需要如实说明："真实"一行在12月9日确实显示了一个红色格点，但它位于吉达以北约165公里处（靠近海岸，不在本系统建模的任何一个城市），反映的是原始数据中一个独立的、真实的降雨信号（该格点降水18毫米、CAPE 1700、IVT 339——均为真实数值），**并非吉达事件本身**。我们保留了这一格点、未做任何编辑处理，因为将其移除会低估原始网格数据实际包含的内容； 但如果不加说明地看图，可能会被误认为是对吉达事件的确认——事实并非如此。

下文全部12张地图（本节3张加12.1节9张）的逐日动态GIF版本，已随本报告及已部署的网站一同提供。


三张地图之后，本节其实已经发挥了一次作用：把一处隐藏的核验严格度缺口（达曼热浪）变成了一处可见的、已披露的缺口。随之而来的问题显而易见——如果绘制3个事件的地图就能发现问题，那绘制全部12个事件的地图又会发现什么？

12.1 扩展核验：来自完整评审事件清单的另外9个事件


上文绘制地图的3个事件，是评审老师提供的完整2025年事件清单的一部分（清单还包含4轮热浪、3次沙尘暴，以及——按照 原文自己的标注，尽管实际仅列出5个日期段——"6起"洪水事件）。其余全部9个日期段均采用相同方法（ `DetectionEngine.risk_field` 独立规则得分 对比 `forecast_tool` 模型概率，在整个网格上计算）绘制地图并逐一核验。完整的逐事件详情见配套报告 `MAZU_Real_Hadise_Dogrulama_CN.pdf` （英文版： `..._EN.pdf` ）。



沙尘暴 (Haboob) , 5月4-5日 — 无法判定：全部8个建模城市均无真实信号（吉达最高0.35，低于阈值）。这次全国性事件的真实高风险区域位于400-800公里外，靠近苏丹/约旦/伊拉克边境——超出本系统8城市的覆盖范围。这是一个如实的发现，而非漏报：并非每个清单事件都落在本系统的覆盖范围内。




沙尘暴, 6月30日-7月5日 — 强命中：本轮核验中最清晰的命中案例。利雅得，6月30日：真实得分1.00，模型0.99。达曼，7月1-5日：真实得分持续0.35-0.60，模型概率0.77-0.91——真实信号与模型判断在空间和时间上高度吻合。




热浪第二轮, 6月28日-7月5日 — 未命中：一次真实的模型漏报。6月30日，达曼真实规则得分达到0.55（恰好达到 阈值）——规则引擎独立确认当地条件符合热浪标准——但模型仅给出

0.045，远低于阈值。如实披露为一次真实漏报，未做掩饰。




热浪第三轮，7月20-27日 — 部分命中：点名城市未命中，麦加独立命中。官方通报达曼/焦贝
尔/AI-Ahsa温度达 48-50°C；但达曼自身原始数据仅达到40.2-43.8°C，低于规则引擎45°C的
阈值——点名城市均无真实信号。与此同时在麦加 发现了一次独立、真实的命中：7月22日真
实0.60/模型0.97，7月23日真实0.45/模型0.98。

Heatwave 4th wave, 29 Jul-5 Aug 2025 -- partial hit, Mecca independent hit




热浪第四轮，7月29日-8月5日 — 部分命中：达曼出现一次微弱但真实的吻合（真实0.2，模型0.01-0.05——双方均 低于阈值，并非原文描述的"持续50°C以上"），麦加再次出现独立命中（8月4日：真实0.60，模型0.90）。

Flood, 6-7 Jan 2025 -- inconclusive, data gap + within training period



洪水，1月6-7日 — 无法判定：麦加的真实得分在1月6日达到1.00，但这一结果建立在严重不完整的数据之上：当天CAPE、IVT、PWAT均缺失（NaN），这是已知的1-3月数据缺口，导致规则引擎的自身权重归一化机制将单一可用指标放大为1.00。该日期同时也落在模型的训练窗口内，而非留出的测试期——是一个不可靠的样本，如实标注为无法判定，而非强行给出结论。


Flood, 6-7 Mar 2025 -- real score stays 0.0 at Hail/Buraidah, but model reaches 0.94-0.98 there (not caught in the written report)



洪水，3月6-7日（哈伊勒/布赖代） — 未命中，并有一项新发现：两地全程真实得分均为0.0（由于均不属于本系统建模的8个城市，直接在其原始网格坐标处核验）。但在绘制本地图过程中，发现了原先纯文字核验未曾检查的问题：模型在这两处坐标上，3月6-7日的预测概率高达0.94-0.98——这是一个真实的、此前未披露的模型 / 规则引擎分歧，只有在对整个网格进行可视化后才被发现，而非仅检查单点数值。


这正是支撑第12.1节全部内容的发现——一个纯文字、单点核验永远不可能发现的问题，也是对“为什么要为全部12个事件绘图，而不是止步于3个”这一问题最清晰的回答。

Flood, 14 Aug 2025 (Taif) -- model/real disagreement



洪水，8月14日（塔伊夫） — 模型与真实数据不一致：模型判断领先于真实信号。8月13日：真实0.35，模型0.52。8月14日：真实0.15，模型0.51——两天模型概率均高于操作阈值，而真实规则引擎信号始终偏弱。这可能是模型捕捉到了 塔伊夫山地地形相关的信号（本系统在别处已专门标注该地形置信度警示）——但规则引擎无法独立确认这一具体预警。

Flood, 27-28 Aug 2025 (Asir/Jizan) -- mixed result



洪水，8月27-28日（阿西尔/吉赞） — 结果混合：一次真实的、跨多日的混合结果。阿巴哈，8月26日：真实0.75， 模型0.84——命中。但到8月28-29日，真实值依然高达0.75，而模型概率降至0.37-0.44，未能延续判断。吉赞，8月26-27日：真实0.60，模型仅0.18-0.22——漏报。模型捕捉到了阿巴哈事件的第一天，但错过了事件的持续性及其在吉赞一侧的影响。

下表汇总全部12个已核验事件。

事件	结果
达曼沙尘暴（5月17日）	✔ 命中
达曼高温热浪（6月13日）	⚠ 部分命中（已更正）
吉达特大洪水（12月9-10日）	✖ 未命中 — 数据分辨率局限
Haboob沙尘暴（5月4-5日）	— 无法判定，覆盖范围外
沙尘暴（6月30日-7月5日）	✔ 命中（强）
热浪第二轮（6月28日-7月5日）	✖ 未命中
热浪第三轮（7月20-27日）	⚠ 部分命中，含重要澄清
热浪第四轮（7月29日-8月5日）	⚠ 部分命中
洪水（1月6-7日）	— 无法判定，数据缺口+训练期内
洪水（3月6-7日）	✖ 未命中 — 真实值0.0，但模型在哈伊勒/布赖代达到0.94-0.98（新发现）
洪水（8月14日塔伊夫）	⚠ 模型与真实数据不一致
洪水（8月27-28日）	⚠ 结果混合

全部12个事件汇总：3个清晰命中，3个清晰未命中，4个部分命中 / 结果混合，2个因明确说明的方法论原因 无法判定——一个真实、有起伏的分布，而非精心挑选的"全部命中"样本。9个新增核验中的一项还发现了与上文（第12节）已披露的 同一类验证严格度问题的第二个实例：评审老师7月20-27日的预警点名达曼、利雅得温度达48-50℃，但这两个城市自身的原始网格 温度全程均低于44.3℃——与此同时，在麦加发现了一次独立、真实的命中（7月22日）。为全部12个事件绘制完整网格地图（而非仅检查点名城市的单点数值）还发现了第三处问题：3月6-7日在哈伊勒/布赖代，规则引擎的真实值全程为0.0，而模型 预测概率却高达0.94-0.98——这是一处仅靠单点核验无法发现的真实模型 / 规则引擎分歧，只有在对空间场进行可视化后才被 发现。每一条结论背后的完整推理见配套报告。

十二个事件，用同样如实的方式核验，无论结果好看与否——包括三个不同的时刻（第二节的热浪更正、本节的哈伊勒/布赖代发现，以及麦加与达曼-利雅得的不一致）——过程本身发现自己

不够严格，并公开更正，而非悄悄修改。

十三、线上部署

完整系统，包括本报告在内的全部文档，均已部署在 <https://turgutino.github.io/mazu-saudi-warning/>（GitHub 仓库：[turgutino/mazu-saudi-warning](https://github.com/turgutino/mazu-saudi-warning)）。上述每一项扩展功能在被报告为“完成”之前，均已在线上部署站点（而不仅是本地）完成验证。

十四、下一步正在考虑的方向

方向	预计工作量	当前状态
智能体阿拉伯语应答支持	低—中	考虑中
正式的知识图谱选型对比文档（说明为何采用自建方案而非 SWEET / GeoSPARQL / WMO Ontology / KnowWhereGraph 等）	低	考虑中
将干旱作为第4种灾害（全深度：数据集、探测、模型、知识图谱）	高	考虑中
接入 KnowWhereGraph 外部知识图谱	中	已降低优先级——相较于我们已针对 8 个城市/3 种灾害构建完善的自有知识图谱，预期边际收益有限
更新展示用幻灯片以反映当前实际进展	中	进行中
建立人工审核流程，将 literature_evidence_tool 的候选结果升级进入正式知识图谱	低—中	考虑中
为 literature_evidence_tool 构建进程内多跳证据图（networkx，无需外部数据库）——跨文献串联事实，而非仅返回单篇文献的top-k结果（见9.13节）	低—中	已降低优先级——当前语料库仅12条，预期收益尚不足以支撑该工作量
多日预测时效（在目前提前1天的基础上，扩展到2天、3天或一周预测）（见第六节）	中—高	考虑中——由导师 / 审阅老师反馈直接提出

更精细的空间分辨率（优于10公里），以更好捕捉类似12月9-10日吉达洪水这种被漏检的短时局地强对流事件（见第十一节）	高	考虑中——取决于是否能获取更高分辨率的原始数据
---	---	-------------------------

表格中的每一行，都可以追溯到上文某处已披露的具体局限——这份清单是这些局限接下来的去向，而不是被遗忘的地方。

附录 — 完整统计数据一览

指标	数值
覆盖灾种数	3（山洪、极端高温、沙尘暴）
覆盖城市数	8（Jeddah、Mecca、Riyadh、Jizan、Dammam、Taif、Medina、Abha）
知识图谱节点 / 边	60 / 183
支撑机制的同行评审文献引用	6条（来自7篇引用文献）
智能体工具数	7
单元测试数（agent/02_test_tools.py + 校准 / 集成测试脚本）	237（169 + 68），0 个失败
全系统审计检查项（FULL_SYSTEM_AUDIT.py）	121 / 121 通过
原始数据源	365 个逐日 NetCDF 文件，约 5 GB，0.1° 分辨率
训练 / 测试划分	2025年1–6月训练，2025年7–12月测试（按时间划分，无数据泄漏）
线上站点	turgutino.github.io/mazu-saudi-warning